No.13 標本統計

NAKADA Masayuki

Kobe University Secondary School

November 2, 2021

標本調査(309のスライドより)

標本調査: 母集団 (調査の対象全体) を全数調査することが難しい場合, 一部を無作為に抽出し (標本), 全体を推測する.

- 母集団の情報:母平均μ,母標準偏差σ
 - ▶ 直接の把握は困難
- 標本の情報:標本平均 X,標本標準偏差 σ(X)
 - ▶ 調査によって把握可能
 - ▶ 抽出した標本によって、値が揺れる $\leftarrow \overline{X} \circ \sigma(X)$ もまた確率変数!

把握可能な \overline{X} , $\sigma(X)$ から母集団の分布の情報 μ や σ を推測する.

※今回は、母集団が平均 μ 、標準偏差 σ の正規分布 $N(\mu,\sigma)$ に従うものとする.

標本平均の平均と標準偏差

 $X_1, X_2, \ldots, X_n \sim N(\mu, \sigma^2)$ (n 個の標本を無作為に抽出した)のとき,標本平均 $\overline{X}_n = \frac{1}{n} \left(X_1 + X_2 + \cdots + X_n \right)$ の平均 $E(\overline{X}_n)$ と標準偏差 $\sigma(\overline{X}_n)$ について,調べよう.

$$E(\overline{X}_n) = E\left(\frac{1}{n}(X_1 + \dots + X_n)\right) = \frac{1}{n}(E(X_1) + \dots + E(X_n)) = \frac{n\mu}{n} = \mu,$$

$$V(\overline{X}_n) = V\left(\frac{1}{n}(X_1 + \dots + X_n)\right) = \frac{1}{n^2}(V(X_1) + \dots + V(X_n)) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

$$(\dots X_1, \dots, X_n \text{ は独立であると仮定した.})$$

上の計算は、 X_i たちが同一の分布に従うならばいつでも正しい.

NAKADA Masayuki (KUSS) DS I November 2, 2021

さらに、正規分布は再生性(後述)をもつため、 \overline{X}_n も正規分布に従う.

標本平均の分布

 $N(\mu,\sigma^2)$ に従う大きさ n の無作為標本の標本平均は,平均 μ ,標準偏差 $\frac{\sigma}{\sqrt{n}}$ の正規分 布 $N\left(\mu,\frac{\sigma^2}{n}\right)$ に従う: $\overline{X}_n \sim N\left(\mu,\frac{\sigma^2}{n}\right)$.

e.g. 母平均 50,母標準偏差 10 をもつ小集団から,大きさ 100 の標本を無作為抽出するとき,その標本平均 \overline{X} が 52 より大きい値をとる確率を求めよう(問 25). \overline{X} は平均 50,標準偏差 $\frac{10}{\sqrt{100}}=1$ の正規分布に従う.その標準化 $Z=\frac{\overline{X}-50}{1}=\overline{X}-50$ は標準正規分布に従うから

$$P(\overline{X} \ge 52) = P(Z \ge 2) = 0.5 - 0.4772 = 0.0228$$

により、およそ2.3%である.

標本分散について

母平均が既知のとき、「標本分散」 $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$ の平均は

$$E(S_n^2) = E\left(\frac{1}{n}\sum_{i=1}^n (X_i - \mu)^2\right) = \frac{1}{n}\sum_{i=1}^n E\left((X_i - \mu)^2\right) = \frac{1}{n}\sum_{i=1}^n V(X_i) = \sigma^2$$

より, $E(S_n^2)=\sigma^2$ である.しかし,標本調査において,母平均 μ の値が既知であることは稀である.そこで,母平均 μ を標本平均 $\overline{X}=\frac{1}{n}\sum_{i=1}^n X_i$ に置き換えた

$$S^{2} = S_{n}^{2} = \frac{1}{n} \sum_{i=1}^{n} (X_{i} - \overline{X}_{n})^{2}$$

を,標本分散として扱う.

標本分散について

母平均が既知のとき、「標本分散」 $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$ の平均は

$$E(S_n^2) = E\left(\frac{1}{n}\sum_{i=1}^n (X_i - \mu)^2\right) = \frac{1}{n}\sum_{i=1}^n E\left((X_i - \mu)^2\right) = \frac{1}{n}\sum_{i=1}^n V(X_i) = \sigma^2$$

より, $E(S_n^2)=\sigma^2$ である.しかし,標本調査において,母平均 μ の値が既知であることは稀である.そこで,母平均 μ を標本平均 $\overline{X}=\frac{1}{n}\sum_{i=1}^n X_i$ に置き換えた

$$S^{2} = S_{n}^{2} = \frac{1}{n} \sum_{i=1}^{n} (X_{i} - \overline{X}_{n})^{2}$$

を,標本分散として扱いたいところであるが,実はこのSでは $E(S^2) = \frac{n-1}{n}\sigma^2$ と過小評価してしまう.特に,あまり大きくない標本(n < 100程度)においては影響が無視できない.

標本から母分散に近い値を取り出すためには、さらに式に修正を加えて

$$\hat{S}^2 = \hat{S}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \overline{X}_n)^2$$

を標本分散として扱えばよい. \hat{S}^2 を**標本不偏分散**という. \hat{S}^2 は $E(\hat{S}^2) = \sigma^2$ を満たす.

※標本不偏分散がnでなくn-1で割られているのは,2乗和 $\sum_{i=1}^{n}(X_i-\overline{X})^2$ の式において,固定された \overline{X} の下で X_1,\ldots,X_n のうち n-1 個の値が決まれば,残り 1 個の X_i の値は,条件式 $\overline{X}=\frac{1}{n}\sum_{i=1}^{n}X_i$ への束縛により決まってしまう(「自由度がn-1」という)ことに由来する.

※統計量 θ (e.g. 母平均,母分散など母集団のもつパラメタ)とその標本推定量T (e.g. 標本平均,標本分散などの確率変数)に対し, $E(T)=\theta$ が成り立つとき,その標本推定量は**不偏推定量**であるという.不偏推定量は,統計量の付近に分布することが期待されるため,標本から母集団を推測するのに都合がよい.統計的推定については,次回詳しく扱う.

自由度

n 個の変数 x_1, x_2, \ldots, x_n に k 個の関係式からなる「系(system)」

$$F_1(x_1, x_2, ..., x_n) = 0$$

$$F_2(x_1, x_2, ..., x_n) = 0$$

$$\vdots$$

$$F_k(x_1, x_2, ..., x_n) = 0$$

が与えられると、(特殊な場合を除き)自由に値を設定できる変数はn-k個である. このとき、系の自由度はn-kであるという.

χ^2 分布

 Z_1, Z_2, \ldots, Z_n が標準正規分布 N(0,1) に従う独立な確率変数であるとき、確率変数

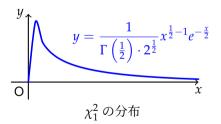
$$Y = Z_1^2 + Z_2^2 + \dots + Z_n^2$$

の従う分布のことを、自由度nの χ^2 (カイ自乗) 分布といい、 χ^2_n で表す.

※ガンマ分布の式をよく見れば、 $Z_i^2 \sim G_A\left(\frac{1}{2},2\right)$ であることが分かる(詳細は後述).また、ガンマ分布は再生性をもつので、 $\chi_n^2 = G_A\left(\frac{n}{2},2\right)$ である.

ガンマ分布 $G_A(\alpha,\beta)$ の確率密度関数:

$$f(x) = \frac{1}{\Gamma(\alpha) \cdot \beta^{\alpha}} x^{\alpha - 1} e^{-\frac{x}{\beta}}$$



以降は補足と発展的な話題

$Z \sim N(0,1)$ のとき $Z^2 \sim G_A\left(\frac{1}{2},2\right)$ であることについて

置換積分の技術(数学III)を援用すると、分布関数の比較により証明できる.

$$\begin{split} P(Z^2 &\leq u) = P(-\sqrt{u} \leq Z \leq \sqrt{u}) \\ &= \int_{-\sqrt{u}}^{\sqrt{u}} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \, dx = 2 \int_0^{\sqrt{u}} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \, dx \\ &= 2 \int_0^u \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{y}{2}\right) \cdot \frac{dy}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi}} \int_0^u y^{-\frac{1}{2}} e^{-\frac{y}{2}} \, dy \\ &= \int_0^u \frac{1}{\Gamma\left(\frac{1}{2}\right) \cdot 2^{\frac{1}{2}}} y^{\frac{1}{2} - 1} e^{-\frac{y}{2}} \, dy \quad (\because \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}) \end{split}$$

これは、ガンマ関数の分布関数を与えている. なお、途中で $y=x^2$ として置換積分を行っている.このとき、 $0 \le x \le \sqrt{u}$ において、 $\frac{dy}{dx}=2x$ により $dx=\frac{dy}{2\sqrt{u}}$ である.

NAKADA Masayuki (KUSS) DS I November 2, 2021 10/14

標本不偏分散の自由度について(再訪)

正規分布に従う標本 $X_1, \ldots, X_n \sim N(\mu, \sigma)$ について, $S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X})^2$ を考える.標準化 $Y_i = \frac{X_i - \mu}{\sigma}$ を行うと, $Y_1, \ldots, Y_n \sim N(0, 1)$ であり,

$$\frac{nS^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} - \frac{\overline{X} - \mu}{\sigma} \right)^2$$

$$= \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 - 2 \sum_{i=1}^n \frac{X_i - \mu}{\sigma} \cdot \frac{\overline{X} - \mu}{\sigma} + \sum_{i=1}^n \left(\frac{\overline{X} - \mu}{\sigma} \right)^2$$

$$= \sum_{i=1}^n Y_i^2 - n \left(\frac{\overline{X} - \mu}{\sigma} \right)^2 \qquad (\because X_1 + \dots + X_n = n\overline{X})$$

が成り立つ. 次のような変数変換 $(Y_1, ..., Y_n) \leftrightarrow (Z_1, ..., Z_n)$ を行う.

NAKADA Masayuki (KUSS) DS I November 2, 2021

$$Z_{1} = \frac{Y_{1}}{\sqrt{n}} + \frac{Y_{2}}{\sqrt{n}} + \dots + \frac{Y_{n}}{\sqrt{n}}$$

$$Z_{2} = \frac{Y_{1}}{\sqrt{1 \cdot 2}} - \frac{1 \cdot Y_{2}}{\sqrt{1 \cdot 2}}$$

$$Z_{3} = \frac{Y_{1}}{\sqrt{2 \cdot 3}} + \frac{Y_{2}}{\sqrt{2 \cdot 3}} - \frac{2 \cdot Y_{3}}{\sqrt{2 \cdot 3}}$$

$$\vdots$$

$$Z_n = \frac{Y_1}{\sqrt{(n-1)n}} + \dots + \frac{Y_{n-1}}{\sqrt{(n-1)n}} - \frac{(n-1)Y_n}{\sqrt{(n-1)n}}$$

この変換は、次を満たす.

$$\sum_{i=1}^{n} Y_i^2 = \sum_{i=1}^{n} Z_i^2, \ Z_1 = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} Y_i = \frac{\sqrt{n}(\overline{X} - \mu)}{\sigma} \sim N(0, 1), \ Z_2, \dots, Z_n \sim N(0, 1)$$

よって,

$$\frac{nS^2}{\sigma^2} = \sum_{i=1}^n Y_i^2 - n \left(\frac{\overline{X} - \mu}{\sigma}\right)^2 = \sum_{i=1}^n Z_i^2 - Z_1^2 = \sum_{i=2}^n Z_i^2$$

この計算結果は, $\frac{nS^2}{\sigma^2} = \sum_i (X_i - \overline{X})^2$ が自由度 n-1 の χ^2 分布に従うことを示している.※変数変換 $(Y_1,\ldots,Y_n) \leftrightarrow (Z_1,\ldots,Z_n)$ はいわゆる直交変換である.行列計算を行うと,見通しがよくなる.

再生性

二項分布,正規分布,ガンマ分布などは,以下の性質をもつことが知られている.

$$X \sim B(m, p), \quad Y \sim B(n, p) \Rightarrow X + Y \sim B(m + n, p)$$

 $X \sim N(\mu_1, \sigma_1^2), \quad Y \sim N(\mu_2, \sigma_2^2) \Rightarrow X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$
 $X \sim G_A(\alpha_1, \beta), \quad Y \sim G_A(\alpha_2, \beta) \Rightarrow X + Y \sim G_A(\alpha_1 + \alpha_2, \beta)$

これらのように、同種の確率分布に従う2変数について、その和も同種の確率分布に従うとき、その確率分布族(一連の確率分布の集まり)は**再生性**をもつという. 上記のことから、二項分布、正規分布、ガンマ分布は再生性をもつ. 証明には、畳み込みなどの高度な積分技術が必要であるため、ここでは省略する.