```
1 import numpy as np
2 import scipy.stats as stats
3 import pandas as pd
4 # import matplotlib.pyplot as plt
5 # import seaborn as sns
```

▼ モジュール pandas について

データを集めて分析をするには、収集したデータの整理が必要になる。 モジュール pandas は、データを表にして管理したり、表からさまざまな項目のデータを抽出したりするのに利用される.

次のコードを実行してから、先の内容を読み進めること、

▼ Series オブジェクト

series オブジェクトは、1列の表を扱う、配列のようなものである。次のコードによって、上で定義した ser1 を出力してみよ。

また,メソッド.values, .index を ser1 につけると,出力がどのように変化するか,コメントアウトを外して確認せよ.

```
1 # 上のセルから、ser1というSeriesオブジェクトについて出力する
2 #ser1
3 ser1.values
4 # ser1.index
array([66, 76, 82, 63, 59, 52, 87, 61, 73, 68, 55, 67, 64])
```

▼ DataFrame オブジェクト

2次元配列を扱うには、DataFrame オブジェクトを利用する.

```
1 # 上のセルから、df1というDataFrameオブジェクトを出力する2 df13 # df1.T # 行と列を入れ替える(Tは転置、Transposeの意)
```

- 4 # df1.Birth_Month # 特定の1列のみを取り出す場合の書き方
- 5 # df1[["Math","Birth_Month"]] # 複数の列を取り出す場合の書き方
- 6 # df1["English"][5] # English列の第5行を取り出す場合

| | Number | Name | Math | English | Birth_Month | 17. |
|---|--------|----------|------|---------|-------------|-----|
| 0 | 4401 | Akao | 66 | 61 | February | |
| 1 | 4402 | Ozawa | 76 | 73 | June | |
| 2 | 4403 | Kurokawa | 82 | 68 | August | |
| 3 | 4404 | Tominaga | 63 | 55 | November | |
| 4 | 4405 | Negoro | 59 | 67 | April | |
| 5 | 4406 | Yano | 52 | 64 | October | |
| 6 | 4407 | Yokota | 87 | 74 | June | |

▼ 条件に合う行の抽出

データフレームから、条件に合う行を抽出するには、以下のセルのように条件式を書けばよい。

1 # df1[df1["Birth_Month"] == "June"] # Birth_Month列がJuneであるデータのみを抽出 2 df1[df1["Math"] >= 60] # Mathの成績が60以上であるデータのみを抽出

| Birth_Month | English | Math | Name | Number | |
|-------------|---------|------|----------|--------|---|
| February | 61 | 66 | Akao | 4401 | 0 |
| June | 73 | 76 | Ozawa | 4402 | 1 |
| August | 68 | 82 | Kurokawa | 4403 | 2 |
| November | 55 | 63 | Tominaga | 4404 | 3 |
| June | 74 | 87 | Yokota | 4407 | 6 |

▼ 行のソート(並び替え)

データフレームの特定の列を数値の順に並び替えるには、sort.values() メソッドを利用して、以下のセルのように書けばよい。 詳しくは、 こちらなどを参照。

- 1 df1.sort_values("English") # 英語の成績で昇順にソート
- 2 # df1.sort_values("English", ascending=False) #降順にソートしたい場合は, ascending=False

| j) | Birth_Month | English | Math | Name | Number | |
|----|-------------|---------|------|----------|--------|---|
| | November | 55 | 63 | Tominaga | 4404 | 3 |
| | February | 61 | 66 | Akao | 4401 | 0 |
| | October | 64 | 52 | Yano | 4406 | 5 |
| | April | 67 | 59 | Negoro | 4405 | 4 |

外部ファイルからデータを取得する方法

以下では、Notebookファイルと同一のフォルダに配置されたExcel、CSVのデータを読み込む方法、および、ColaboratoryのNotebookファイルと同一のフォルダに配置されたSpreadsheetデータの読み込み方について解説する。

以下では、各自利用している環境に合わせて、実行するコードを選ぶこと、

▼ Jupyter Notebookのローカル環境下での作業用

CSV形式のファイルからデータを読み込む場合は、このまま下のセルを実行する.

Excel形式のファイルからデータを読み込む場合は、下のセルの $8 \sim 9$ 行目をコメントアウト(行頭に # を加える)し、 $2 \sim 5$ のコメントアウトを外す。

- 1 # Excelファイルから読み込む場合
- 2 # excel_file_name = "DogOrCat_Test.xlsx" # 読み込むファイル名を文字列として入力(拡張子を)
- 3 # xl_data = pd.ExcelFile(excel_file_name) # データをxl_dataに格納
- 4 # sheets = xl_data.sheet_names # Excelのシートのリストを作成
- 5 # df = x1_data.parse(sheets[0]) # 0番目のシートのデータをDataFrame形式にしてdfに格納
- 7 # CSV形式のファイルから読み込む場合
- 8 csv_file_name = "DogOrCatOr_4-3.csv" # 読み込むファイル名を文字列として, csv_file_nameに
- 9 df = pd.read_csv(csv_file_name) # データをDataFrame形式にしてdfに格納

▼ Google Colab内での作業用

Google Colaboratoryを使用する場合は、Google Drive内に置いたスプレッドシートからデータを読み込む必要がある。

基本的には、スプレッドシートのURLを下のコードの所定の場所に貼り付け、順にコードを実行すればよい. 詳細は、このQiitaの記事などを参考にされたい.

- 1 # 必要なモジュールのインストール
- 2 !pip install --upgrade -q gspread
- 1 # 必要なモジュールのインポート
- 2 from google.colab import auth

```
3 from oauth2client.client import GoogleCredentials
4 import gspread
5
6 # GoogleDriveをColaboratoryにロードする(認証作業あり)
7 auth.authenticate_user()
8 gc = gspread.authorize(GoogleCredentials.get_application_default())
9
10 # 文字列urlに読み込むスプレッドシートのURLを入力
11 url = "https://docs.google.com/spreadsheets/d/lym4x88o522lPyvcLuv-SmB5D4o3xa1afl
12
13 sheet = gc.open_by_url(url).get_worksheet(0) # urlに指定したURLから,スプレッドシートのC
14 df = pd.DataFrame(sheet.get_all_values()) # sheetのデータをDataFrame形式にしてdfに格
15 df
```

| | 0 | 1 | 7 | | | |
|----------------------|----------------|------------|---|--|--|--|
| 0 | RandNum | DogOrCatOr | | | | |
| 1 | 0.002127418695 | 「犬派」 | | | | |
| 2 | 0.0116918293 | 中立 | | | | |
| 3 | 0.02330211606 | 中立 | | | | |
| 4 | 0.03087775439 | 「猫派」 | | | | |
| | | | | | | |
| 110 | 0.9854067944 | 中立 | | | | |
| 111 | 0.9866553689 | 「猫派」 | | | | |
| 112 | 0.9869737949 | 「犬派」 | | | | |
| 113 | 0.9903752154 | 「犬派」 | | | | |
| 114 | 0.9928164818 | 「犬派」 | | | | |
| 115 rows × 2 columns | | | | | | |

模擬アンケート結果の分析

先週採ったアンケートの結果の分析を行おう.

問題設定

「模擬アンケート①」に回答した10回生を母集団とし、回答者から無作為に抽出した20人の回答結果から、母集団における「犬派」と回答した人数を、信頼度95%の信頼区間を求めることにより、推測する。

- 1. 抽出するサンプル数 n を20に設定する.
- 2. 信頼度を設定する. ここでは α を,信頼区間が母集団における「犬派」と回答した人数を推定し損なう確率として,信頼度 $(100(1-\alpha)\%)$ を間接的に設定する.

分析

- 1. 回答結果を収めたデータフレーム(df,上のセルで定義したもの)の行数(総回答数)を L とする.
- 2. リスト[1,L](1以上L以下の整数値)から20個(nに格納した値)の一様乱数(どの整数も等確率で選ばれる、一様分布に従う乱数)を非復元抽出(randlist)し、抽出した乱数に対応する回答のみを含むデータフレームを構成する(df.iloc[randlist]).
- 3. df.iloc に含まれる「犬派」の回答件数を計上し、n_dog に格納する. このとき、抽出した標本における「犬派」の割合 p_dog は

```
p_{dog} = n_{dog} / n
```

と計算される.

- 4. 母集団における「犬派」の割合(**母比率**)を,標本における「犬派」の割合 p_dog から,信頼度を 95%として,以下の考え方に従って区間推定せよ.
 - 1. 母集団(大きさL=全回答数)のうち「犬派」が k_{dog} 件であるとする. 母比率は $\frac{k_{\mathrm{dog}}}{L}$ である.
 - 2. そこから無作為に大きさn=20の標本を(非復元)抽出する. 標本に含まれる「犬派」 の割合 $p_{\mathrm{dog}}=\frac{n_{\mathrm{dog}}}{n}$ は、母比率の推定量となる.
 - 3. 母集団から大きさn=20の標本を無作為抽出するとき、標本の中に含まれる「犬派」の割合は、二項分布 $B(1,p_{\mathrm{dog}})$ に従うとみなせる。この二項分布を近似する正規分布 $N\left(1\cdot p_{\mathrm{dog}},1\cdot p_{\mathrm{dog}}\cdot (1-p_{\mathrm{dog}})\right)$ から大きさn=20の標本を抽出すると考えて、上下2.5%点の値 $(z_{0.025}=1.96)$ を求めることで、信頼度95%の信頼区間

$$egin{aligned} egin{aligned} p_{
m dog} - z_{0.025} \cdot \sqrt{rac{p_{
m dog} \cdot (1-p_{
m dog})}{20}}, & p_{
m dog} + z_{0.025} \cdot \sqrt{rac{p_{
m dog} \cdot (1-p_{
m dog})}{20}} \end{aligned} \end{bmatrix}$$
の計算式に代入する。

分析結果の集約

1. クラスルームに配布されている, フォーム「114_Estimation_Interval_test_4-3」に, 上下側信頼 限界を入力する.

```
    コードのあとに 母比率の推定に関する解説を載せている 必要に応じて参昭してほしい
    1 # 抽出するサンプル数を指定する
    2 n = 20
    3        
            4 # 信頼度の設定(1-aが信頼度, つまり, aは閾値を超える辺境の確率を定めている)
            5 a = 0.05

    6        
            7 # 標準正規分布の累積分布関数の値がa/2となるxの値をパーセント点から求めている(累積分布関数の逆関数8 z_ppv = stats.norm.ppf(1 - a / 2, loc=0, scale=1)
```

 $9 \# t_ppv = sp.stats.t.ppf(1 - a / 2, n - 1)$

```
11 print("標準正規分布に基づく",100*(1-a/2),"%点の値は:",z_ppv)
12 # print("自由度",n-1,"のティー分布に基づく",100*(1-a/2),"%点の値は:",t_ppv)
13
14 L = len(df) # DataFrameの行数の取得
15 ser = np.arange(1,L+1) # JZF[1,L]
16 randlist = np.random.choice(ser,n,replace=False) # N個の乱数のリストを生成
17
18 # 回答結果のDataFrameから上の乱数リストのindexを抜き出し、標本の中で「犬派」と回答している件数をた
19 print("抽出された標本の回答結果は以下の通り:\n",df.iloc[randlist,1])
20 n_dog = len(df.iloc[randlist,1][df.iloc[randlist,1] == "「犬派」"])
21 p_{dog} = n_{dog} / n
22 print("「犬派」の回答件数は,",n_dog,"件であり,その標本に占める割合は,",p_dog)
23
24
25 # 標本平均の信頼度(1-a)の上側信頼限界と下側信頼限界を求めている
26 I_dogL = p_dog - z_ppv * np.sqrt(p_dog * (1 - p_dog) / n)
27 \text{ I\_dogU} = p\_dog + z\_ppv * np.sqrt(p\_dog * (1 - p\_dog) / n)
28 print(100*(1-a),"%信頼区間は",[I_dogL,I_dogU])
29
30 \# I_{dog_tL} = p_{dog} - t_{ppv} * np.sqrt(p_{dog} * (1 - p_{dog}) / n)
31 \# I_{dog_tU} = p_{dog} + t_{ppv} * np.sqrt(p_{dog} * (1 - p_{dog}) / n)
32 # print("ティー分布に基づいて計算した",100*(1-a),"%信頼区間は",[I_dog_tL,I_dog_tU])
    --NORMAL--
    標準正規分布に基づく 97.5 %点の値は: 1.959963984540054
    抽出された標本の回答結果は以下の通り:
          「猫派」
    66
         「犬派」
    70
         「犬派」
    90
         「犬派」
    10
        「犬派」
    60
    43
         「猫派」
    26
        「犬派」
        「犬派」
    84
    11
        「犬派」
        「犬派」
    99
    41
        「犬派」
         「犬派」
    28
    68
         「猫派」
        「犬派」
    36
        「犬派」
    85
        「犬派」
    38
        「犬派」
    51
    95
           中立
    25
         「犬派」
    92
          中立
    Name: 1, dtype: object
    「犬派」の回答件数は、15 件であり、その標本に占める割合は、0.75
    95.0 %信頼区間は [0.5602273032177509, 0.9397726967822491]
```

一般論(母比率の推定)

1. 母集団Uにおける,性質Aをもつ個体の含まれる割合を調べたい.大きさnの標本を無作為抽出すると,性質Aをもつ個体がk個あった.このことから,母集団における性質Aをもつ個

体の比率(母比率)の信頼度 $100(1-\alpha)$ %の信頼区間は

$$\left\lceil \frac{k}{n} - z_{\frac{\alpha}{2}} \cdot \sqrt{\frac{\frac{k}{n} \cdot \left(1 - \frac{k}{n}\right)}{n}}, \quad \frac{k}{n} + z_{\frac{\alpha}{2}} \cdot \sqrt{\frac{\frac{k}{n} \cdot \left(1 - \frac{k}{n}\right)}{n}} \right\rceil$$

で与えられる. 教科書では, $p_0 = \frac{k}{n}$ として表記している.

2. 厳密には、母分散が未知であるから、ここで推定するためのパーセント点として正規分布のも のではなく、母分散を標本不偏分散に置き換えた、自由度n-1のティー分布のパーセント点 を利用することになる.

$$\left\lceil \frac{k}{n} - t_{\frac{\alpha}{2}}(n-1) \cdot \sqrt{\frac{\frac{k}{n} \cdot \left(1 - \frac{k}{n}\right)}{n}}, \quad \frac{k}{n} + t_{\frac{\alpha}{2}}(n-1) \cdot \sqrt{\frac{\frac{k}{n} \cdot \left(1 - \frac{k}{n}\right)}{n}} \right\rceil$$

ティー分布については教科書で触れられていないが、KP等で統計的処理を行い、推定を行う 際には知っておくべき存在である。

【解説】母比率の推定

十分な大きさの母集団Uにおいて、性質Aをもつ個体の含まれる割合が p_0 であるとする. このと き, 母集団Uから無作為に1個の個体を抽出して, 性質Aをもつ確率は p_0 である. 確率変数Xを, 抽 出した個体が性質AをもつときX=1, もたないときX=0で定義すると、Xは二項分布 $B(1, p_0)$ に従う: $X \sim B(1, p_0)$.

母集団Uから個体をn個抽出し、大きさnの標本 $[s_1, s_2, \ldots, s_n]$ を作る. s_i の性質の有無を確率変 数 X_i で表すことにする. $X_i \in B(1, p_0)$ であり, (二項分布は再生性をもつので)

$$\sum_{i=1}^n X_i=X_1+X_2+\cdots+X_n\sim B(n,p_0).$$

 $B(n, p_0)$ を、(平均と分散を等しくする)正規分布 $N(np_0, np_0(1-p_0))$ に置き換える:

$$\sum_{i=1}^n X_i \sim N\left(np_0, np_0(1-p_0)
ight)$$

この結果から, $\overline{X}=rac{1}{n}\sum_{i=1}^n X_i$ の平均と分散は

$$E\left(\overline{X}\right) = E\left(\frac{1}{n}\sum_{i=1}^{n}X_{i}\right) = \frac{1}{n}E\left(\sum_{i=1}^{n}X_{i}\right) = \frac{1}{n}\cdot np_{0}$$

$$V\left(\overline{X}
ight) = V\left(rac{1}{n}\sum_{i=1}^{n}X_i
ight) = rac{1}{n^2}V\left(\sum_{i=1}^{n}X_i
ight) = rac{1}{n^2}\cdot np_0(1-p_0)$$

$$=\frac{p_0(1-p_0)}{1-p_0}$$

 $=rac{p_0(1-p_0)}{n}.$ ゆえに, $\overline{X}\sim N\left(p_0,rac{p_0(1-p_0)}{n}
ight)$ である.

あとの流れは,区間推定の求め方に従う.

- <本授業の学び>

本授業で学んだことを,下のテキストボックスに記入して下さい.

(ここに本授業の学びを記入する)